

Separabilidade Linear de Verbos Psicológicos no XLM-RoBERTa-base

Josué D. Praciano¹, Vivian dos Santos Silva¹

¹Programa de Pós-Graduação em informática, Universidade Federal do Rio de Janeiro
(UFRJ)

Rio de Janeiro, RJ, Brasil

josuepraciano@letras.ufrj.br

Abstract. *Situated within the field of Natural Language Processing (NLP), this paper evaluates the extent to which vector representations from the XLM-RoBERTa-base model capture deep syntactic-semantic properties, such as thematic roles. Furthermore, the study investigates whether this capability enables the model to discriminate among psych-verb subclasses without relying on fine-tuning or prior syntactic annotation.*

Resumo. *Inserido na área de Processamento de Linguagem Natural (PLN), este artigo avalia em que medida as representações vetoriais do modelo XLM-RoBERTa-base capturam propriedades sintático-semânticas profundas, como papéis temáticos. Ademais, a investigação busca verificar se essa capacidade do modelo permite discriminar subclasses de verbos psicológicos sem o recurso de ajuste fino (fine-tuning) ou de anotações sintáticas prévias.*

1. Introdução

Os modelos Transformer representam uma arquitetura de rede neural que trouxe tanto avanços significativos quanto novos questionamentos para o Processamento de Linguagem Natural (PLN) ao introduzir o mecanismo de autoatenção (*self-attention*). Esse mecanismo permite o processamento de dados em paralelo e a captura de relações contextuais complexas entre os *tokens* de uma sequência. Nessa categoria, o XLM-RoBERTa (XLM-R)¹ destaca-se como um modelo de linguagem mascarado e multilíngue, desenvolvido pela Meta com base em otimizações do RoBERTa e treinado sobre dados de mais de 100 idiomas extraídos do *Common Crawl*. Ao aprender representações textuais universais sem depender de corpora paralelos de tradução, o XLM-R é capaz de transferir o conhecimento adquirido entre línguas para resolver diversas tarefas de PLN, como classificação, extração de entidades e resposta a perguntas (Conneau *et al.*, 2020). No entanto, questões sobre como as relações entre entidades são internamente estruturadas e quais propriedades semântico-sintáticas são efetivamente codificadas pelo modelo permanecem como importantes focos de investigação.

Diante da capacidade do modelo em capturar relações contextuais complexas, torna-se relevante avaliar seu desempenho em tarefas linguísticas de nível equivalente. Nesse cenário, os verbos psicológicos no Português Brasileiro (PB) constituem um desafio substancial para a análise computacional, pois apresentam ambiguidades intrínsecas na atribuição de papéis temáticos. Em termos práticos, frases sintaticamente

¹ Também se trata de um modelo *Open Source* disponível na plataforma [Hugging Face](#)

semelhantes podem envolver mapeamentos temáticos inversos a depender do verbo empregado, como ilustrado em (1a) e (1b):

1.
 - a) O aluno (Experienciador) gosta da aula (Tema).
 - b) A aula (Tema) agrada o aluno (Experienciador).

Essa classe de verbos é reconhecida na literatura por associar o papel temático de experienciador a um de seus argumentos, o qual pode ocupar a posição sintática de sujeito ou de objeto. Ademais, Cançado (1996) os categorizou em quatro subtipos: Classe 1 (verbos como *temer*), Classe 2 (verbos como *preocupar*), Classe 3 (verbos como *abrandar*) e Classe 4 (verbos como *animar*). As especificidades de cada classe e os critérios de categorização serão detalhados ao longo deste trabalho.

Para contextualizar a motivação deste trabalho, é importante ressaltar como o XLM-R processa as estruturas linguísticas. Após a tokenização do texto (a segmentação das sentenças em tokens²), o modelo gera vetores em um espaço de alta dimensionalidade. Para fins deste experimento, optou-se pelo XLM-R-base (com 768 dimensões), em razão de limitações de hardware local, em detrimento de versões maiores, como a *large* (com 1024 dimensões). Investiguei, assim, se essas representações vetoriais são capazes de capturar nuances semânticas suficientes para permitir a separação linear entre as diferentes categorias de verbos psicológicos, sem a necessidade de *fine-tuning* ou de anotação sintática explícita.

Para investigar a natureza das representações internas aprendidas por modelos de linguagem pré-treinados as técnicas de *probing* são o principal meio de diagnosticar o conhecimento linguístico codificado nesses espaços vetoriais, pois permitem determinar até que ponto propriedades estruturais, sintáticas e semânticas específicas estão implicitamente codificadas e prontamente acessíveis em suas camadas internas. (Conneau *et al.*, 2018) Ao longo deste trabalho, também será melhor explicado que tipo técnicas foram usadas para esta finalidade.

O objetivo principal deste trabalho consiste, assim, em avaliar a separabilidade linear de quatro classes de verbos psicológicos do Português Brasileiro, estruturadas com base na taxonomia de Cançado (1996), em comparação com uma classe de controle composta por verbos de transferência (Berlink, 1996). Especificamente, busca-se investigar em que medida as representações vetoriais (*embeddings*) extraídas do modelo XLM-RoBERTa-base codificam essas distinções semântico-pragmáticas no seu espaço de representação, sem a necessidade de ajuste fino (*fine-tuning*) ou supervisão sintática adicional.

É importante ressaltar que esta pesquisa consolida um padrão de rigor metodológico ao estruturar um *pipeline* reproduzível e auditável via grafo de proveniência de dados. Pois, em um contexto em que a falta de transparência em experimentos com modelos de linguagem pode comprometer a validação científica, a arquitetura proposta assegura o rastreamento ponta a ponta desde a criação do corpus

² O tokenizador do XLM-RoBERTa é baseado no algoritmo *SentencePiece*. Basicamente, o texto é processado diretamente a partir dos bytes brutos, sem depender de etapas prévias de pré-tokenização específicas de um idioma (como divisão por espaços ou pontuação).

até as etapas de sondagem linear (*probing*). Para isso, adotou-se o modelo PROV-DM (W3C) como diretriz de documentação, aproveitando sua estrutura padronizada para aproximar este trabalho dos princípios *FAIR* da Ciência Aberta.

2. Fundamentação Teórica e Trabalhos Relacionados

2.1. Verbos Psicológicos no Português Brasileiro:

É do interesse deste trabalho se aprofundar, ao menos o suficiente, no que remete à classe de verbos psicológicos e suas características, ainda que de maneira superficial, tendo em vista que não se faz necessário um debate linguístico, mas sim uma exposição da literatura relacionada. Dessa forma, começemos sobre o que exatamente são os verbos psicológicos. São uma classe de verbo que necessitam de um argumento experienciador de traço [+ animado] que está vivenciando um processo ou estado mental. (Cançado, 1996, Belletti; Rizzi, 1988).

Existem diversas literaturas que têm como foco definir, estudar e entender essa classe de verbos, como Belletti e Rizzi (1988) e Mendes (2002, 2003). Porém, são estudos que focam no funcionamento desses verbos em outras línguas, como Português Europeu e Italiano. No entanto, para o PB, Cançado tem uma série de trabalhos que se colocam na posição de se aprofundar nesse tema, por isso foi escolhido como literatura base.

Cançado (1996) definiu os verbos psicológicos em quatro classes distintas, cada uma com seu grupo de características associadas (Tabela 1). Como mencionado na introdução, as classes são: Classe 1 (verbos como *temer*), Classe 2 (verbos como *preocupar*), Classe 3 (verbos como *abrandar*) e Classe 4 (verbos como *animar*). Ademais, convém destacar que a autora distribuiu 360 verbos entre as quatro categorias, porém não de forma equivalente: a Classe 1 contém 48 verbos; Classe 2, 130; Classe 3, 35; Classe 4, 90. Tal disparidade quantitativa é uma informação importante para a construção do corpus, pois alerta para cuidados afim de manter o equilíbrio entre as classes.

Propriedade	Classe 1 (temer)	Classe 2 (preocupar)	Classe 3 (acalmar)	Classe 4 (animar)
Posição do Experienciador	Exp-suj	Exp-obj	Exp-obj	Exp-obj
Ligação anafórica	-	+	+	+
Ergatividade	-	+	+	+
Causatividade	-	+	+	+

Inversão	+	-	-	-
Tipo de Passiva	+p.sin	+p.adj	+p.sin	+p.sin e adj
<i>pro</i> (Nominalização/Processo)	+	-	+	+
c.enc (Clivada/Cláusula encaixada)	+	-	+	+

Tabela 1 - Lista das diferenças de cada Classe

Fonte: Cançado (1996, p. 10)

No que se pode articular sobre às classes, primeiramente, apenas a Classe 1 apresenta o experienciador marcado como sujeito, enquanto nas outras três essa marcação se concentra no objeto. Ademais, tendo em vista que o foco deste trabalho não é se debruçar sobre as características que diferenciam as classes, já que o objetivo é justamente descobrir se elas são diferenciáveis sem um corpus dedicado a essas propriedades sintáticas, explicarei apenas sucintamente o que cada uma representa.

A frase (2a) estabelece a estrutura canônica da Classe 1 dos verbos psicológicos, na qual o experimentador surge obrigatoriamente na posição de sujeito e o tema na de objeto. As demais propriedades em (2) comprovam o rigor dessa hierarquia argumental: a impossibilidade de alternância ergativa (2b) e de causativa direta (2c) evidencia que causa não pode assumir a posição de sujeito sem violar a grade temática do verbo; a alternância de constituintes (2d) reafirma a flexibilidade do Estímulo como adjunto ou objeto direto; a admissão da passiva sintática em detrimento da adjetival (2e) demonstra que temer expressa um estado mental ativo, e não uma propriedade resultativa fixada no objeto; e, por fim, a aceitação de sujeito arbitrário (2f) e de causativa encabeçada (2g) confirma que a introdução de uma causa externa exige um verbo auxiliar (fazer), reiterando que o verbo temer evita a conversão direta de seu tema em sujeito.

2.

- a) José (Exp) teme o cachorro pelo seu tamanho
- b) *O cachorro (se) teme pelo seu tamanho.
- c) *O tamanho teme o cachorro.
- d) José teme o tamanho do cachorro.
- e) O cachorro é temido por José / *O cachorro ficava temido com José.
- f) Teme-se o cachorro pelo seu tamanho.
- g) O amigo faz José temer o cachorro.

(Cançado, 1996, p.6 e p.7)

A diversidade de propriedades sintáticas que caracterizam as classes de verbos psicológicos sugere, à primeira vista, a necessidade de um corpus igualmente rico e complexo para viabilizar sua distinção. No entanto, essa exigência só se justifica se a diferenciação entre as classes for de natureza puramente sintática, e não semântica. Diante disso, este trabalho busca delimitar a fronteira mínima de complexidade necessária para que o modelo XLM-R-base consiga distinguir esses verbos, investigando se um corpus com estruturas mais simples, como orações no infinitivo, é suficiente ou se é necessário uma maior diversidade sintática interna.

2.2. Sondagem de Representações Vetoriais:

A literatura de *probing classifiers* fundamenta-se na premissa de que a qualidade de uma representação vetorial (*embedding*) pode ser avaliada pela facilidade com que propriedades linguísticas específicas podem ser extraídas dela. Essa técnica é utilizada para diagnosticar quais informações os codificadores de sentenças retêm em seus *embeddings* (Conneau *et al.*, 2018).

A premissa básica do método de sondagem (*probing*) é que, se um classificador treinado sobre vetores congelados (sem ajuste fino nos *embeddings*) obtém sucesso em uma tarefa específica (como identificar o tempo verbal), isso indica que o codificador pré-treinado está armazenando informações legíveis sobre essa propriedade nos *embeddings* que cria. Se a informação não estivesse acessível ou presente, o classificador não conseguiria aprender a tarefa de forma eficaz apenas a partir do vetor fixo.

3. Metodologia

Para esta pesquisa, o pipeline foi dividido em três etapas: I. Construção de um corpus dedicado a este trabalho; II. Extração de *features* (*embeddings*) por meio do modelo XLM-RoBERTa-base; III. Classificação supervisionada com algoritmos lineares. Por último, foram adotadas boas práticas para garantir a reprodutibilidade e a proveniência, assegurando a integridade dos dados.

3.1 Criação do Corpus

Inicialmente, tendo em vista a escassez de corpora dedicados aos verbos psicológicos no (PB), foi necessária a construção e a curadoria dos dados do corpus. Dessa forma, com base na taxonomia proposta por Cançado (1996), foram criadas listas de verbos para cada uma das quatro classes e a classe controle (Berlinck, 1996), as quais foram posteriormente extraídas do Corpus do Português (Davies, 2018).

Quanto ao corpus do qual foram extraídas manualmente as estruturas, trata-se do Corpus do Português, uma plataforma que reúne diversos corpora anotados da língua portuguesa. Entre as diferentes opções oferecidas pela ferramenta, foi usado nesta pesquisa o Corpus NOW (2012-2019), composto por 1,1 bilhão de palavras coletadas na internet ao longo dos anos mencionados e segmentadas entre quatro países lusófonos. Ademais, a plataforma viabiliza consultas por palavra, expressão, lema entre outras categorias o que permitiu a busca por verbos psicológicos específicos.

Para dar prosseguimento à criação do corpus, foram definidas quatro classes de verbos psicológicos (Cançado, 1996) e uma classe de controle de verbos de transferência (Berlinck, 1996). Esta última foi selecionada por sua distância semântica, servindo para criar um contraste mínimo. Com isso, caso as classes não fossem linearmente separáveis, a separação bem-sucedida da classe de controle demonstraria que eventuais limitações decorreram do comportamento dos verbos psicológicos e não necessariamente de falhas no modelo.

A seleção dos verbos fundamentou-se naqueles que mais se aproximavam do modelo prototípico ideal (Mendes, 2002, 2003), isto é, verbos puramente psicológicos. Essa escolha justifica-se pelo fato de que muitos verbos categorizados como psicológicos por Cançado (1996) dependem fortemente do contexto para assumir tal sentido. Por exemplo, na Classe 3, apenas cerca de 10 são puramente psicológicos por natureza (como apaixonar), enquanto os demais (como triturar, regenerar e derrotar) exigem contextos específicos para essa interpretação.

Além da variação semântica, identificou-se uma assimetria quantitativa, pois a autora selecionou 360 verbos divididos em quatro categorias de tamanhos muito díspares, visto que, enquanto a Classe 3 conta com um número reduzido de verbos puramente psicológicos, as demais classes apresentam em torno de 89 verbos cada. Diante desse cenário, a fim de balancear o dataset e manter a mesma proporção entre as categorias, a amostragem foi limitada pelo tamanho da menor classe, estabelecendo-se o total de 10 verbos puramente psicológicos para cada uma das quatro classes. Por fim, a seleção dos verbos das Classes 1, 2 e 4 seguiu uma ordem meramente alfabética.

Classe 1	Classe 2	Classe 3	Classe 4
admirar, adorar, amar, desejar, detestar, estranhar, invejar, odiar, almejar, apreciar	Aborrecer, afligir, abalar, chatear, comover, decepcionar, encantar, escandalizar, apaixonar, constranger	Acalmar, Apaziguar, Convencer, Enganar, Humilhar, Ludibriar, Pacificar, derrotar, Ridicularizar, Tranquilizar,	Acovardar, Agradar, Alarmar, Alegrar, Atormentar, Animar, Apavorar, Assombrar, Assustar, Aterrorizar

Tabela 2 - Lista de verbos Psicológicos

Controle: Verbos de Transferência
dar, atribuir, devolver, distribuir, emprestar, entregar, fornecer, oferecer, pagar, transferir

Tabela 3 - Lista de verbos de transferência

Quanto à estrutura e à quantidade das sentenças, optou-se pelo uso de orações com verbos no infinitivo (cf. 3a e 3b), escolha que visou neutralizar marcas morfossintáticas de pessoa, número e modo, além de facilitar a etapa de tokenização pelo modelo. A definição do número de estruturas por verbo representou um desafio metodológico, visto que muitas buscas no Corpus do Português retornavam menos de 50 ocorrências no infinitivo. Diante dessa limitação, estipulou-se o total fixo de 50 sentenças por verbo, utilizando esse valor como critério mínimo para a inclusão do verbo no estudo e descartando aqueles que não atingiram tal amostragem.

3.

a) O objetivo central de a festa é agradar os moradores

b) Dalila vai apavorar Miguel em Órfãos de a Terra

(Frases retiradas do corpus e presentes no dataset)

Por último, as estruturas passaram por uma organização, foi criado um json com id único para cada frase, verbo alvo, classe e em qual posição o verbo se encontra. Tudo para que seja possível a melhor visualização do corpus por outros pesquisadores.

3.2 Estratégias de *pooling*

De forma resumida, o processamento de uma frase pelo modelo XLM-R-base inicia-se com a sua divisão em *tokens*, aos quais são atribuídos vetores de alta dimensionalidade. Como o corpus contém estruturas de comprimentos variados, aplica-se o procedimento de *padding* (inserção de *tokens* <pad>) às sequências menores, tendo como referência a estrutura mais longa do conjunto. Dessa forma, para evitar que esses tokens extras introduzam ruído nos dados, aplicou-se uma máscara na camada de *pooling*, garantindo assim que fossem ignorados. Em seguida, visando obter uma representação do contexto geral da frase em que o verbo se encontra, realizou-se a média dos vetores dos *tokens* (*mean pooling*). Por fim, os embeddings foram extraídos das últimas quatro camadas do modelo, visto que, conforme apontam Jawahar *et al.* (2019), é nelas que se encontram codificadas as informações semânticas mais complexas em arquiteturas desse tipo.

3.3. Classificação

Para a etapa de classificação, os dados foram divididos na proporção de 80% para treinamento e 20% para teste, adotando-se a amostragem estratificada para preservar a distribuição original das classes em ambos os conjuntos. No conjunto de treino, aplicou-se a validação cruzada *Stratified K-Fold* ($k=5$) para o ajuste e avaliação intermediária dos modelos, foi usado ($k=5$) seguindo os estudos de (Abedin *et al.*, 2026) que detalhou como em dataset menores, k com valores altos (10) geraria um número pequeno de amostras, que teria como resultado uma alta variância entre os *folds*.

Foram avaliados dois algoritmos de aprendizado supervisionado, a Regressão Logística e o SVM Linear (*Support Vector Machine*), ambos selecionados por sua baixa complexidade. A escolha da Regressão Logística fundamenta-se em sua adoção em trabalhos anteriores da área, como no estudo de Conneau *et al.* (2020). Por outro lado, o SVM Linear foi incluído como modelo comparativo, embora seja empregado em tarefas

diversas de Processamento de Linguagem Natural (PLN), identificou-se uma lacuna quanto à sua aplicação específica neste tipo de análise, o que motivou a investigação de seu desempenho no presente experimento.

Por fim, a avaliação do desempenho preditivo foi conduzida utilizando as métricas de Acurácia, F1-Score (nas ponderações *Macro* e *Weighted*) e a Matriz de Confusão. Adicionalmente, para mensurar a coesão e a separabilidade das classes no espaço de representação vetorial bruto (*embeddings*), calculou-se o *Silhouette Score* utilizando a distância de cosseno.

3.4. Proveniência e Reprodutibilidade:

Para assegurar a transparência, a rastreabilidade e a reprodutibilidade dos experimentos, o fluxo de execução adota o padrão PROV-model, desenvolvido pelo *World Wide Web Consortium* (W3C), mapeando detalhadamente o grafo de proveniência de todas as etapas de processamento (Imagem 1). Além disso, a infraestrutura do estudo está publicamente disponível em um repositório no [GitHub](#), composto por *scripts* devidamente documentados e instruídos para execução. Por fim, visando garantir a consistência estatística, o processo de avaliação utilizou validação cruzada, aliado à fixação de todas as sementes aleatórias (*seeds*) para a reprodução dos resultados obtidos.




Figura 1 - Grafo completo de proveniência

4. Resultados e Análise

4.1. *Silhouette Score*

Para avaliar a separabilidade das representações vetoriais dos verbos sem a intervenção de rótulos de classe, calculou-se o *Silhouette Score* global sobre o espaço vetorial utilizando a métrica de distância por cosseno. Dessa forma, o valor obtido foi de [-0,0070].

Um *Silhouette Score* próximo de zero (e levemente negativo) indica uma ausência da separabilidade estrutural entre as categorias analisadas no espaço vetorial.

Esse resultado confirma que os verbos não formaram *clusters* naturais ou isolados antes do treinamento supervisionado. Assim, a distribuição dos *embeddings* sugere uma sobreposição expressiva entre os vetores de diferentes classes, refletindo que o modelo de linguagem capturou similaridades semântico-contextuais amplas que não se organizaram espontaneamente em fronteiras rígidas correspondentes às subclasses de verbos psicológicos.

4.2. Desempenho dos Classificadores Lineares:

A avaliação do desempenho dos modelos lineares (Regressão Logística e SVM Linear) através de Validação Cruzada e no conjunto de teste final de 500 instâncias (100 por classe) é apresentada na Tabela 4:

Modelo	Acurácia (CV k=5)	Acurácia (Teste)	Precisão (Macro)	Recall (Macro)	Recall (Macro)
Regressão Logística	84,75% ($\pm$ 0,79%)	87,40%	0,87	0,87	0,87
SVM (Linear)	83,95% ($\pm$ 0,64%)	85,60%	0,86	0,86	0,86

Tabela 4: Desempenho comparativo dos classificadores lineares.

A Regressão Logística obteve o melhor desempenho global, atingindo (87,40%) de acurácia no conjunto de teste, superando levemente o SVM Linear (85,60%). Ademais, a proximidade nos resultados da validação cruzada (84,75% vs. 83,95%) aparentam indicar boa estabilidade e generalização de ambos os classificadores

Classe	Regressão Logística (Prec / Rec / F1)	SVM Linear (Prec / Rec / F1)
Classe 1	0,89 / 0,89 / 0,89	0,89 / 0,88 / 0,88
Classe 2	0,81 / 0,74 / 0,77	0,75 / 0,72 / 0,73
Classe 3	0,83 / 0,90 / 0,86	0,81 / 0,89 / 0,85
Classe 4	0,90 / 0,87 / 0,88	0,87 / 0,84 / 0,85
Controle	0,94 / 0,97 / 0,96	0,97 / 0,95 / 0,96

Tabela 5: Métricas de desempenho por classe no conjunto de testes.

A Classe Controle obteve o maior desempenho global, atingindo um *F1-Score* de 0,96 em ambos os modelos. Esse resultado é motivado pelo comportamento sintático-semântico mais simples e de estruturas mais coerentes com a classe de verbos. Dessa maneira, os resultados altos não foram uma surpresa.

De maneira oposta, a Classe 2 registrou o menor desempenho preditivo da avaliação, atingindo *F1-Score* de 0,77 na Regressão Logística e de 0,73 no SVM. A queda expressiva nas métricas de precisão e *recall* decorre, em grande medida, de verbos com baixos índices de acerto individual, a exemplo de constranger (47,1% de acerto em ambos os modelos) e encantar (50,0% no SVM e 66,7% na Regressão Logística). O comportamento instável desses itens deve-se ao fato de serem frequentemente confundidos pelos classificadores com verbos pertencentes às Classes 3 e 4.

Por sua vez, as Classes 1, 3 e 4 mantiveram um desempenho sólido e bastante equilibrado, com *F1-Scores* situados no intervalo entre 0,85 e 0,89. Dentro desse bloco, foram destacados verbos como almejar e estranhar (Classe 1), enganar e ludibriar (Classe 3), além de acovardar, apavorar e aterrorizar (Classe 4), todos com 100% de acurácia individual na maioria dos cenários testados.

4.3. Análise Visual e Espacial (t-SNE)

Para análise visual, seria possível uma ampla possibilidade de ferramentas que serviriam para essa finalidade. Entretanto, foi usado o (t-SNE) devido a sua otimização para visualização de dados alocados em um contexto de alta dimensionalidade, como é o caso dos outputs gerados pelo XLM-R-base (van der Maaten *et al.* 2008).

A análise da distribuição espacial dos embeddings dos verbos por meio do t-SNE (Figura 2) revela uma baixa separabilidade intrínseca global entre as quatro classes de psico-verbos (Classes 1 a 4). Assim, conforme observado, as classes 1 (azul), 2 (laranja), 3 (verde) e 4 (vermelho) encontram-se amplamente entrelaçadas na região central e inferior do gráfico, tal resultado, também confirma o silhouette score baixo.

Verbos pertencentes a categorias semânticas distintas ocupam vizinhanças imediatas, por exemplo, o verbo constranger (Classe 2) está posicionado próximo a enganar, apaziguar e acalmar (Classe 3), enquanto atormentar (Classe 4) situa-se na mesma projeção. Esse comportamento confirma que as representações vetoriais dos verbos psicológicos não formam clusters naturais e isolados em um espaço não-supervisionado, ou pelo menos, não formaram com esse dataset simplificado.

Em contraste, a Classe de Controle (pontos pretos, representando verbos de transferência) apresenta um isolamento topológico notável. Pois, a maior parte de seus membros forma um agrupamento denso e separado dos verbos psicológicos, demonstrando que o espaço vetorial capta uma diferença semântica entre verbos psicológico e verbos de transferência. A única exceção é o verbo dar, que se projeta mais próximo de verbos da Classe 4 (agradar) e Classe 1 (desejar), mas isso deve ocorrer, provavelmente devido à sua alta polissemia em corpora textuais, dito isso, deve ser tratado como uma exceção.




Figura 2- Visualização de *embeddings* via t-SNE

4.4 Discussão Linguística e de PLN

Apesar de haver resultados com um *silhouette score* baixo e um respectivo embaralhamento dos verbos, houve resultados positivos. Primeiramente, a classe controle sendo separada dos verbos psicológicos, mostra que o modelo consegue sim separar semanticamente verbos diferentes, assim, possivelmente, o corpus foi suficiente para isso. Entretanto, fica evidente que um corpus com mais propriedades sintáticas seria necessário para que se começasse a considerar uma separação das subclasses, tendo em vista o quão semanticamente são parecidas.

Ambos os classificadores apresentaram desempenho consistente para a tarefa, com métricas equilibradas que evitaram, aparentemente, tanto o *overfitting* (sobreajuste) quanto o subdesempenho. Ainda assim, para fins comparativos, recomenda-se que trabalhos futuros explorem arquiteturas distintas, como as redes neurais sugeridas por Conneau *et al.* (2020). Ademais, cabe ressaltar que a adoção dessas abordagens exige cautela e a implementação de testes de controle rigorosos, evitando que os modelos apenas memorizem a tarefa em vez de aprender as estruturas subjacentes.

Por fim, ressalta-se que os verbos psicológicos constituem um objeto de estudo de difícil extração em corpora. Pois, a construção de uma amostra diversificada em

estruturas internas, alinhada ao arcabouço de propriedades de Cançado (1996), impõe expressiva complexidade metodológica, visto a dificuldade encontrada para mapear mesmo 50 estruturas distintas no infinitivo. Ademais, a extensão na qual essa limitação dos dados impactou o desempenho dos classificadores permanece como uma questão aberta, uma vez que a alta variabilidade do material (como oscilações no tamanho das sentenças, presença de sujeitos nulos e uso de pronomes reflexivos) pode ter favorecido a confusão entre as subclasses.

5. Conclusão e Trabalhos Futuros

Reitera-se a relevância dos resultados positivos alcançados, uma vez que eles permitem aprofundar a compreensão tanto sobre o limiar mínimo necessário para que o modelo XLM-RoBERTa-base diagnostique conceitos semânticos quanto sobre a própria natureza do objeto de estudo. Em síntese, observa-se que o modelo é capaz de separar linearmente determinadas classes verbais sem a necessidade de ajuste fino (*fine-tuning*). Contudo, a distinção entre subclasses pertencentes a uma mesma categoria revelou-se uma tarefa complexa, exigindo investigações adicionais sobre o perfil e a representatividade do corpus requerido para tal desambiguação.

Essas limitações e achados direcionam a formulação de trabalhos futuros em três frentes principais. Em primeiro lugar, pretende-se expandir a análise para um contexto multilíngue, explorando o uso nativo do modelo XLM-R. Em segundo lugar, busca-se avaliar diferentes arquiteturas de classificação, incluindo o emprego de redes neurais. Por fim, considerando a separação linear bem-sucedida entre os verbos psicológicos e os verbos de transferência, projeta-se a transição para outros objetos de estudo que disponham de conjuntos de dados consolidados, a exemplo dos datasets do *Universal Dependencies*.

Referências

- Abedin, T., Xu, H., and Uddin, S. (2026) “The impact of K selection in K-fold cross-validation on bias and variance in supervised learning models”, *Scientific Reports*, v. 16, n. 1, p. 6084.
- Belletti, A. and Rizzi, L. (1988) “Psych-verbs and θ -theory”, *Natural Language & Linguistic Theory*, v. 6, n. 3, p. 291-352.
- Berlinck, R. (1996) “The Portuguese dative”, In: *Case and Grammatical Relations Across Languages: The dative*, Edited by William Van Belle and Willy Van Langendonck, John Wiley & Sons, Philadelphia, p. 119-152.
- Cançado, M. (1996) “Verbos Psicológicos: Análise Descritiva dos Dados do Português Brasileiro”, *Revista de Estudos da Linguagem*, v. 4, n. 1, p. 89-114.
- Conneau, A., Kruszewski, G., Lample, G., Barrault, L., and Baroni, M. (2018) “What you can cram into a single $\&!\#*$ vector: Probing sentence embeddings for linguistic properties”, In: *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, Melbourne, Australia, p. 2126–2136.

- Conneau, A., Khandelwal, K., Goyal, N., Chaudhary, V., Wenzek, G., Guzmán, F., Grave, E., Ott, M., Zettlemoyer, L., and Stoyanov, V. (2020) “Unsupervised Cross-lingual Representation Learning at Scale”, In: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, Online, p. 8440–8451.
- Davies, M. (2016) “Corpus do Português: Web/Dialects”, Available online at: <http://www.corpusdoportugues.org/web-dial/>.
- Jawahar, G., Sagot, B., and Seddah, D. (2019) “What Does BERT Learn about the Structure of Language?”, In: *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, Florence, Italy, p. 3651–3657.
- Mendes, A. (2002) “Uma análise dos verbos psicológicos com base nos dados de um corpus”, In: *Encontro comemorativo dos 25 anos do CLUP*, Edited by Inês Duarte et al., CLUP, Porto, v. 1.
- Mendes, A. (2003) “A expressão da emoção em predicados verbais do português”, In: *Análise contrastiva de variedades do português: primeiros estudos*, Edited by Silvia Figueiredo Brandão and Maria Alice Mota, In Fólio, Rio de Janeiro.
- van der Maaten, L. and Hinton, G. (2008) “Visualizing data using t-SNE”, *Journal of Machine Learning Research*, v. 9, p. 2579-2605.