

Investigando a Separabilidade Linear de Verbos Psicológicos no XLM-RoBERTa



Josué David Praciano

1. Introdução

1.1 A Complexidade dos Verbos Psicológicos:

Diferente de verbos de ação (como quebrar), os verbos psicológicos descrevem estados mentais onde a relação entre quem sente (Experienciador) e o que causa o sentimento (Tema).

A Tipologia (Cançado, 1997):

Classe I (Sujeito Experienciador): "O aluno (Exp) gosta da aula (Tema)".

Classe II (Objeto Experienciador): "A aula (Tema) agrada o aluno (Exp)".

Qual é a menor unidade de informação necessária para que um modelo diferencie a estrutura da Classe 1 da Classe 2?

1. Introdução

1.2 Hipótese:

Utilizar o XLM-RoBERTa (modelo Transformer multilingue) para extrair vetores numéricos (embeddings) das sentenças.

Pois se o modelo captura nuances semânticas (papéis temáticos), os vetores das diferentes classes ocuparão regiões distintas no hiperespaço, permitindo a separabilidade linear.

2. Metodologia

2.1 Construção do Dataset:

Dataset dividido em:

Classe 1, Classe 2 e Controle (Agentivos)

Total por Classe:

20(Verbos) x 15(sentenças) = 300 sentenças

Tipos de estrutura:

SVO e Passivas

Fonte dos Dados: Corpus do Português (Davies, 2017).

<https://www.corpusdoportugues.org/>

- 1.1b de palavras extraídas de jornais e revistas (2012-2019)

2. Metodologia

2.2 Extração de Features (XLM-RoBERTa)

1. **Pré processamento do Corpus:** Limpeza, normalização, filtragem de sentenças.
2. **Tokenização:** XLM-RoBERTa
3. **Pooling:** mean Token

2.3 Arquitetura de Classificação

- **Regressão Logística / SVM Linear:** Se um classificador linear funcionar, prova-se que a estrutura dos dados já está organizada de forma lógica no *embedding*.

2.4 Visualização (PCA)

- Utilizar **PCA (Análise de Componentes Principais)** para reduzir a dimensionalidade para 2D.

3. Proveniência

Validação Cruzada ($k = 5$)

- Dividirei o dataset d sentenças em k partes. O modelo treina em k-1 partes e testa na parte restante, repetindo o processo até que todos os dados tenham sido testados.

Fixar uma semente(ex: seed = 9) para todas as bibliotecas usadas.

Versionamento do código.

ID único para cada frase.