



Investigando a Separabilidade Linear de Verbos Psicológicos no XLM-RoBERTa

Autor: Josué David Praciano

Introdução

1.1 A Complexidade dos Verbos Psicológicos:

Diferente de verbos de ação (como quebrar), os verbos psicológicos descrevem estados mentais onde a relação entre quem sente (Experienciador) e o que causa o sentimento (Tema).

A Tipologia (Cançado, 1997):

Classe I (Sujeito Experienciador): "O aluno (Exp) gosta da aula (Tema)".

Classe II (Objeto Experienciador): "A aula (Tema) agrada o aluno (Exp)".

Introdução

1.2 Hipótese:

- Apenas com informações frasais e sem metadados, é possível que um modelo diferencie a estrutura da Classe 1 da Classe 2?
- Se o modelo captura nuances semânticas (papéis temáticos), os vetores das diferentes classes ocuparão regiões distintas no hiperespaço, permitindo a separabilidade linear.
- Utilizar o XLM-RoBERTa (modelo Transformer multilingue) para extrair vetores numéricos (embeddings) das sentenças.

As Fases do Pipeline



1. Extração Manual

Extração manual do Corpus do Português gerando o arquivo processado original processed.json.



2. Extração de Embeddings

O texto é processado pelo XLM-RoBERTa-Base, que combina suas camadas internas e aplica o método de Masked Mean Pooling para maior robustez.



3. Classificação

Treinamento de SVM/Regressão Logística e mapeamento por PCA.

Fase 1: Preparação do Corpus

Origem dos Dados Brutos

Dataset dividido em:

Classe 1, Classe 2 e Controle (Agentivos)

Total por Classe:

20(Verbos) x 15(sentenças) = 300 sentenças

Tipos de estrutura: Verbos no Infinito

Exemplo:

Houve um exagero em abominar a política.

Estruturação em JSON

Frases marcadas com ID, posição do verbo e verbo_alvo para facilitar visualização posteriormente

```
{  
  "id": 1,  
  "texto": "Houve um exagero em abominar a  
política.",  
  "verbo_alvo": "abominar",  
  "posicao_verbo": 4  
},
```

Fase 2: XLM-RoBERTa e Pooling

Para extrair a semântica profunda das sentenças, apliquei o modelo multilíngue **xlm-roberta-base** com as seguintes características:

Últimas 4 Camadas: Extração de uma média das camadas 9-12, a onde, segundo a literatura (Jawahar et al., ACL 2019) se encontra a maior quantidade de informações semânticas.

Masked Mean Pooling: Utilizando o vetor de máscara de atenção (`attention_mask`), o algoritmo garante que os tokens de preenchimento (<pad>) sejam estritamente ignorados no cálculo da média aritmética. Isso evita a diluição e a distorção semântica do vetor final da sentença por elementos artificiais.

Arquivo final: O processamento foi executado em lotes (`batches`). Ao final, a matriz de características consolidada foi persistida em disco através de um arquivo binário encapsulado.

Fase 3: Modelos de Classificação

Parâmetro do Pipeline	Support Vector Machine (SVM)	Logistic Regression (LR)
Função Base	Separação de margem máxima entre classes	Ajuste logístico probabilístico multiclasse
Hiperparâmetros	Kernel Linear (Hiperplanos OVO cumulativos)	Regularização L2 (Abordagem One-vs-Rest)
Artefato Gerado	modelo_svm_linear.joblib	modelo_regressao_logistica.joblib
Relatório de Saída	resultados_Support_Vector_Machine.txt	resultados_Logistic_Regression.txt

Desempenho dos Classificadores

Resultados do Regressao Logistica:

Resultados da Validação Cruzada (5 Folds):

Acurácias por fold:

63.19%, 71.53%, 73.61%, 61.11%, 62.50%

Média do CV: 66.39% (+/- 5.13%)

Acurácia no Teste Final: 79.4444%

Resultados do SVM Linear:

Resultados da Validação Cruzada (5 Folds):

Acurácias por fold:

56.94%, 64.58%, 65.97%, 50.69%, 57.64%

Média do CV: 59.17% (+/- 5.56%)

Acurácia no Teste Final: 72.2222%


Desempenho dos Classificadores

Motivos para os resultados:

- Quantidade limitada do corpus
- Baixa variância interna das estruturas
- Peso elevado em poucos erros
- Verbos de significado dúbio, como: Depreciar, agitar. Em amostras desse tamanho, erros causados por verbos ambíguos têm um peso percentual muito alto na acurácia final

Visualização e Separabilidade linear


Comparativo de Separabilidade Linear dos Verbos (PCA)



Grupos Semânticos


- Grupo 1 (Exp-Suj)
- Grupo 2 (EXP-Obj)
- Grupo 3 (Controle)

SVM Linear (Hiperplanos OVO Reconstruídos)



W3C PROV

Foi gerado tanto um json com toda a relação quanto um png.



Obrigado!